2026 年第八届

全球校园人工智能算法精英大赛

算法创新赛 · AI + 硬件

赛题名称：AI + 硬件

技 术 报 告

团队名称	地境端视
参赛编号	AIC-2026-
作品名称	基于 RDK-X5 的遥感图像边缘智能识别终端
参赛院校	广州软件学院
团队成员	李东澎
指导老师	陈汉添

2026 年 9 月 20 日

目　　录

作品简介 2

一、项目概述 3

（一）项目背景与意义 3

1. 产业背景：模型越来越大，算力却到不了现场 3

2. 场景需求与项目意义 3

（二）赛题方向定位 4

二、系统设计与实现 5

（一）算法：REPB-Net 轻量化变化检测网络 5

（二）边缘端：从浮点权重到 BPU 定点模型 6

（三）软件：端侧一体化检测工作站 7

（四）板卡前端：小屏交互与自适应显示 8

三、实验结果与分析 9

（一）板端量化模型精度 9

（二）一次真实的量化故障排查 10

（三）检测效果可视化 11

四、创新点与应用价值 12

（一）核心创新点 12

（二）应用场景与推广 13

五、附录 14

（一）关键参数速查 14

（二）端侧文件清单与复现步骤 14

作品简介

一句话定义：把「双时相遥感变化检测」这套像素级 AI 算法，从云端 GPU 服务器完整搬进一块 **4 GB 内存、无独立显卡** 的国产边缘算力板卡（RDK X5），并在板端跑通「检测 → 指标评估 → 误差分析 → AI 语义解释 → 结果导出」的完整闭环。

背景与痛点

灾害评估、城市更新与国土监管亟需可现场开展的精准感知。视觉深度网络在精度上持续突破，但参数量与算力需求同步膨胀，推理高度依赖云端 GPU 集群；而云端推理受制于时延、带宽、合规与可用性四重约束，在灾害应急与野外巡检等场景中往往无法落地。

方案与效果

算法上：自研轻量化网络 REPB-Net——共享 MobileNetV2 编码器提取双时相特征，RTRF 互易时相响应融合抑制伪变化，MSRB 多尺度细化桥与 SAM 注意力解码守住细长边界。

硬件上：打通 PyTorch → ONNX → hb_mapper 量化 → RDK X5 BPU 全链路，模型压至 3.2 MB；板端实现检测、评估、误差分析、AI 解释与导出的完整闭环，并实时监控设备温度 / 内存 / CPU。

0.8648	0.7617	3.2 MB	int8
LEVIR-CD F1	IoU	量化模型体积	BPU 定点推理

应用场景

本项目可广泛应用于灾害评估、城市更新与国土监管等场景。以自研轻量化算法为核心、国产边缘算力为载体，打通了从模型训练、量化压缩到端侧推理的全链条，可离线部署于无人机与地面巡检设备，在无网野外完成变化检测与研判，实现**数据不出域、结果不过夜**；更换模型即可平移到其他边缘平台，具备良好的可移植性。

作品定位：这不是「把模型拷到板子上跑一下」，而是围绕边缘硬件的**算力、内存与算子约束**，对算法结构、导出方式与量化策略做系统性适配，最终交付一台**可操作、可演示、可复制**的端侧工作站。详见第一节「（一）项目背景与意义」。

一、项目概述

（一）项目背景与意义

1. 产业背景：模型越来越大，算力却到不了现场

视觉深度网络在变化检测任务上的精度逐年提升，但代价是参数量与算力需求的同步膨胀。推理环节被高度集中在云端 GPU 集群，一旦离开机房，算法能力就难以抵达现场。在灾害应急、野外巡检、国土监测等真实场景中，云端推理面临四重约束：

约束	对业务的实际影响
时延	上行传输与任务排队均不可控，灾后评估按小时计，应急窗口内不可接受
带宽	单景影像百兆级，回传成本高、耗时长，多时相反复上传更不经济
合规	遥感数据出域存在安全与合规风险，部分场景不允许上云
可用性	山区、灾区、海上等现场断网即失效，系统可用性无法保证

> **结论：**把 AI 算法真正下沉到设备端，是智能感知系统能否落地的必答题，也是国产边缘算力的核心命题。本作品正是瞄准这条「最后一公里」。

2. 场景需求与项目意义

遥感变化检测要求从同一区域、不同时相的影像中识别地物变化，是灾后损毁评估、违建与施工监管、国土动态监测的基础能力。该任务对端侧智能提出了三重要求：

- **时效以小时计**——灾害应急场景下，等待回传与排队不可接受；
- **数据量大**——单景影像百兆级，本地处理远优于上传；
- **现场无网**——无人机、巡检车作业区域普遍没有稳定网络。

本作品围绕这三点，把算法、量化与端侧系统作为整体来设计，价值体现在三个层面：

层面	内涵
技术意义	算法与量化**协同设计**：三个自研模块在结构上即为 int8 量化留出余量，配合真实数据校准，量化精度与浮点模型基本持平
工程意义	在 4 GB 板卡上跑通闭环：检测、指标评估、误差分析、AI 语义解释与结果导出集成于单台国产边缘设备，不依赖云端配合即可交付完整结论
产业意义	**数据不出域、结果不过夜**：可离线部署于无人机与地面巡检设备，在无网野外完成变化检测与研判，服务灾害评估、城市更新与国土监管

> **落脚点：**三个层面指向同一件事——让遥感变化检测发生在**数据产生的地方**，而不是数据被运送的目的地。

（二）赛题方向定位

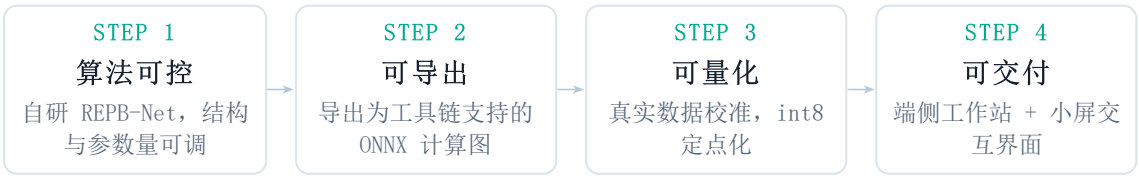
本作品面向「算法创新赛 • AI + 硬件」赛道。与「先做算法、再想办法塞进板子」的常见做法不同，本作品自始至终把**硬件约束当作算法设计的前置条件**：先用芯片的算子集与数值格式反向约束网络结构，再用真实数据校准保证精度，最后把整条链路封装成可交互的端侧系统。四个层面各自回答一个问题：

层面	本作品对应工作	面向的约束
算法	自研轻量化网络 REPB-Net：共享 MobileNetV2 编码器 + RTRF / MSRB / SAM 三个自研模块	双时相伪变化干扰、目标尺度跨度大、细长边界易丢失；同时受限于板端内存与算力，参数量必须小
边缘端	打通 PyTorch → ONNX → hb_mapper 真实校准量化 → RDK X5 BPU 全链路，产出 3.2 MB 定点模型	芯片以 int8 定点运算为主、仅支持有限算子集，浮点模型无法直接运行
软件	端侧一体化工作站：推理引擎 + 指标评估 + 误差分析 + 视觉大模型语义解释 + 结果导出	板卡内存仅 4 GB、无独立 GPU，需控制常驻内存并保证长时间稳定运行
板卡前端	面向 1024×600 板载小屏的自适应深色界面，支持触摸操作与一键启动	屏幕小、无键盘鼠标为主、户外强光环境，信息密度与对比度需专门设计

赛题考察点与本作品应答

考察方向	本作品应答
算法创新性	RTRF 互易时相响应融合、MSRB 多尺度细化桥、SAM 注意力解码三个模块，均针对变化检测的固有难点提出，而非简单套用通用骨干
软硬件协同	导出 opset 受限、量化位宽受限、算子集受限三项硬约束被逐一解决，量化后精度与浮点模型基本持平
工程完整度	不止一段推理脚本，而是可操作、可演示、可交付的完整工作站；全部指标在板端以 int8 模型实测，量化故障的排查过程可复现、可讲解

> **赛道契合点：**AI + 硬件赛道最核心的考察方向，是团队能否围绕硬件的算力、内存与算子约束做**系统性适配**。本作品把「能不能跑」推进到「跑得准、跑得稳、看得懂」——这正是本作品的立题依据。



二、系统设计与实现

（一）算法：REPB-Net 轻量化变化检测网络

REPB-Net 面向「双时相输入、像素级输出」的变化检测任务设计。双时相影像先经过**权重共享**的 MobileNetV2 编码器，被映射到同一语义空间；随后依次经过 RTRF 互易时相响应融合、MSRB 多尺度细化桥与 SAM 注意力解码，输出与原图同分辨率的变化概率图。



图 1 REPB-Net 整体架构：双时相影像经共享编码器进入同一语义空间，再经 RTRF、MSRB、SAM 三级处理输出变化概率图

三个自研模块分别解决什么

模块	做什么	解决的变化检测难点
RTRF	互易时相响应融合：同时构造差异响应 D、能量响应 E 与一致性响应 G，再做通道路由与空间路由	光照、阴影、季节差异造成的**伪变化**在差异响应上很强、在一致性响应上却很弱，借此把「真变化」与「看起来变了」区分开
MSRB	多尺度细化桥：以尺度上下文聚合（SCA）与跨尺度细节融合（CDF）衔接编码器各层级	变化目标**尺度跨度大**，从单栋建筑到大片区开发并存，单一尺度难以兼顾
SAM	注意力解码：在解码阶段对通道与空间位置重新加权	**细长边界**（道路、田埂、围栏）在多次下采样后极易丢失，直接影响面积统计精度

关键设计取舍

- **选 MobileNetV2 而非重型骨干：**板卡内存仅 4 GB 且无独立 GPU，参数量必须优先让位于可部署性；倒残差与深度可分离卷积在精度与体积之间给出较好的平衡点。
- **共享编码器而非双分支：**双时相共用同一套权重，既把参数量压到 247 万，也避免两个分支学到不一致的语义，从根上减少伪变化。
- **以模块换深度：**不靠堆叠层数提升精度，而是用三个针对性模块解决三类具体难点，使网络在轻量化前提下仍守住边界与细节。

（二）边缘端：从浮点权重到 BPU 定点模型

训练完成的 PyTorch 权重只有 10.2 MB，却是 int8 板卡读不懂的浮点格式。本环节的任务，是把它变成 RDK X5 能够直接执行的定点模型，并保证精度不发生明显损失。整条链路分为六步，每一步都对应一次真实的工程决策：



图 2　端侧部署全链路：PyTorch → ONNX → 真实数据校准量化 → RDK X5 BPU

关键参数速查

项目	取值与说明
量化工具链	`openexplorer/ai_toolchain_ubuntu_20_x5_cpu:v1.2.8-py310`（hb_mapper 1.24.3 / hbdk 3.49.15 / horizon_nn 1.1.0）
目标架构	`march = bayes-e`，即 RDK X5 的 BPU 架构
ONNX opset	11——工具链仅支持该版本；导出时按目标版本做算子适配
模型接口	输入 `x1` / `x2` 各 `[1,3,256,256]`，输出 `change_map`
校准数据	从训练集抽取 60 组真实 A/B 影像，按与训练完全一致的预处理生成 float32 裸数据（每组 786,432 字节）
量化配置	`calibration_type: default`；`cal_data_type: "float32; float32"`；`preprocess_on: False`
产物	`repbnet_cd.bin`，3,279,032 字节 ≈ 3.2 MB，较浮点权重压缩约 68%

预处理一致性（全链路最容易翻车的一点）：图像读取 → 6 通道拼接 → 归一化 → 减均值除标准差 → BGR 转 RGB → HWC 转 CHW，**导出、校准、量化、板端推理四处必须完全一致**。本作品将顺序固定为「x1 = 后时相 B 的 RGB、x2 = 前时相 A 的 RGB」，只要有一处不一致，输出就会整体崩坏。

多输入模型的配置规则：凡是与输入个数相关的参数，都要用分号分隔写同样多份（如 `"float32; float32"`），并分别指定各自的校准数据目录。这一条是配置阶段最常踩的坑。

（三）软件：端侧一体化检测工作站

算法跑通只解决了「能不能用」，软件层要回答的是「怎么用」。板端工作站以轻量 Web 应用形式实现：本地 Flask 服务承载界面，浏览器直接访问，模型只加载一次并常驻内存，避免反复调用带来的开销。



功能构成

功能	实现方式与作用
双时相切换对比	前后时相影像叠放，拖动滑块即可对照同一位置的变化，便于人工复核
六视图联动	前时相、后时相、人工标注真值、预测掩膜、叠加图、概率热力图同屏呈现
误差四色图	以 TP（正确变化）/ FP（误报）/ FN（漏检）/ TN（正确负例）四类着色，暗调低饱和配色，一眼看出错在哪里、错成什么样
精度指标	逐像素统计 Precision / Recall / F1 / IoU，并给出 TP、FP、FN、TN 计数，支持置信度阈值实时调节
变化区域点选	自动串出连通区域列表，点击即可在原图上高亮定位，把「面积统计」变成可交互操作
AI 语义解释	调用通义千问视觉大模型 `qwen-vl-max`，把双时相影像、叠加图与检测统计一并送入，输出「哪里变了、变成了什么」的中文短结论
设备实时监控	读取板卡温度、内存与 CPU 占用，以火花线形式常驻显示，体现边缘设备的运行状态
批量评估	对测试集逐对推理并与真值比对，累计 TP / FP / FN / TN，一次性给出全量指标
结果导出	把当前结果图、指标与 AI 文字打包导出，便于归档与答辩演示

> **设计取向：**检测结果不再是一个孤立的二值掩膜，而是「可视化 + 可量化 + 可解释」的三位一体输出。对一线使用者而言，知道「变了多少」和知道「哪里变了、是什么变了」同样重要。

（四）板卡前端：小屏交互与自适应显示

板载屏幕为 1024×600 IPS 触摸屏（约 165 mm × 100 mm），尺寸远小于开发时的电脑显示器。同一套界面必须同时适配两种使用场景：电脑上的调试演示，以及板卡上的现场操作。为此前端采用一套基于相对单位的流式布局，界面元素随屏幕宽度自动缩放与折行。

现场约束	对应设计
屏幕尺寸小	采用流式网格而非固定宽度：主图区与指标区按屏宽自动重排，小屏时纵向堆叠，大屏时并排展开
以触摸为主	扩大按钮点击区，把高频操作固定在底部导航栏，单手可达；阈值调节使用滑杆而非输入框
户外强光	深色低饱和度主题，减少大面积亮色，突出关键指标与变化区域
无键盘鼠标	提供一键启动入口，免去命令行输入，上电后直接进入界面
需要看细节	点击任意结果图进入全屏查看，支持缩放与 1:1 复位，放大后可在屏内平移到目标区域
内存有限	前端只负责展示，全部计算留在后端；图像按需压缩后再传输，避免大图常驻显存与内存

实时监控为什么能反映真实负载

设备监控的数据并非模拟值，而是直接读取板卡的系统接口：温度来自芯片温度传感器，内存来自系统内存统计，CPU 占用来自内核提供的运行计时。因此当推理负载上升时，曲线会同步变化——这使得「边缘实时」不再是一句口号，而是可以在界面上被看到的状态。

> 说明：本项目目前已完成功能与精度的验证，推理帧率与整机功耗尚未做系统测量。这两项将在后续版本中作为标准测试项补齐，用于评估长时间连续运行的可行性。

三、实验结果与分析

（一）板端量化模型精度

全部指标均在 RDK X5 板端以 int8 量化模型实测：逐对影像推理得到概率图，按阈值 0.5 二值化后与人工标注真值逐像素比对，累计 TP / FP / FN / TN 后计算各项指标。

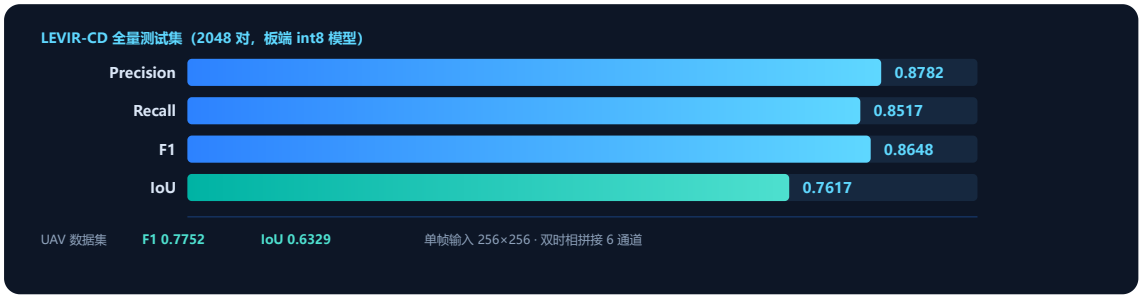


图 3　板端量化模型在 LEVIR-CD 全量测试集与 UAV 数据集上的精度表现

评价指标	LEVIR-CD 全量测试集（2048 对）	UAV 数据集
Precision	0.8782	—
Recall	0.8517	—
F1	0.8648	0.7752
IoU	0.7617	0.6329

2048	256×256	6	0.5
全量测试影像对	单帧输入分辨率	双时相拼接通道数	二值化判定阈值

量化精度的独立验证

为确认量化过程没有损伤模型能力，另做一次浮点自检：绕开量化环节，直接用浮点权重在 CPU 上对同一对影像推理，得到变化像素占比 0.1885，与真值 0.2012 高度接近。该结果说明：预处理链路与网络结构本身是正确的，量化后的指标表现具有可信度，而不是被错误流程掩盖的假象。

> **结论：**模型体积压缩约 68%（10.2 MB → 3.2 MB）后，板端 int8 模型的 F1 仍达 0.8648、IoU 达 0.7617，能够满足变化检测的实际使用要求。在跨数据集的 UAV 数据上 F1 为 0.7752，说明模型具备一定的泛化能力，同时也反映出跨域场景仍是后续优化的重点。

（二）一次真实的量化故障排查

本项目最值得记录的一段过程，是第一次量化后板端输出**全为 0** 的故障。它同时暴露了算法侧与硬件侧的耦合关系，也是最能体现工程判断力的环节。

现象

> **板端实测：**把模型拷入板卡后，运行一对真实变化占比约 20% 的影像，界面输出的「变化像素占比」为 `0.0000`——模型能加载、能推理，却什么也没有检出。

定位：先「分锅」，再动手

出现全 0 结果时，故障可能来自网络结构、预处理链路或量化过程，三者都会导致同样的现象。若直接重新量化，很容易反复试错而找不到问题。因此第一步不是改配置，而是分段定位：绕开量化环节，直接用**浮点权重**在 CPU 上对同一对影像推理。结果浮点预测变化占比 **0.1885**、真值 **0.2012**——**模型与预处理完全正确**，问题被锁定在量化环节。

根因

核查配置后发现，首次使用的配置写的是 `calibration_type: skip`。它的含义是「不提供真实数据，用随机数据完成校准」，仅适合快速验证模型结构能否通过工具链检查，**不能用于真实推理**：

- int8 量化需要知道每一层激活值的**真实分布范围**，才能把浮点数值合理映射到定点区间；
- 随机数据估算出的范围与真实分布不符，量化参数随之失准，模型输出几乎塌缩成一个常数。

修复与验证

环节	做法
生成校准数据	从训练集抽取 **60 组**真实 A/B 影像，按与训练完全一致的预处理，分别生成 x1、x2 的 float32 校准集
改写配置	改用真实校准：`calibration_type: default`，指定两个输入的校准数据目录，并关闭工具链的额外预处理
重新量化	再次执行 makertbin，输出成功；模型体积由 2,820,223 字节增至 **3,279,032 字节**
板端复测	重新拷入板卡运行，变化区域被正常检出，后续全量测试指标即为本文报告结果

> **经验总结：**体积变大并非退步，而是量化器保留了更完整的数值分布信息，模型不再塌缩为常数。这次排查留下的方法论是——**先分锅、再动手**，用一次浮点自检把「模型问题」与「量化问题」分开，避免大量无效试错。

（三）检测效果可视化

下列四联图自左至右依次为：**前时相影像 → 后时相影像 → 人工标注真值 → 模型预测掩膜**，均取自 LEVIR-CD 测试集并由板端量化模型输出。

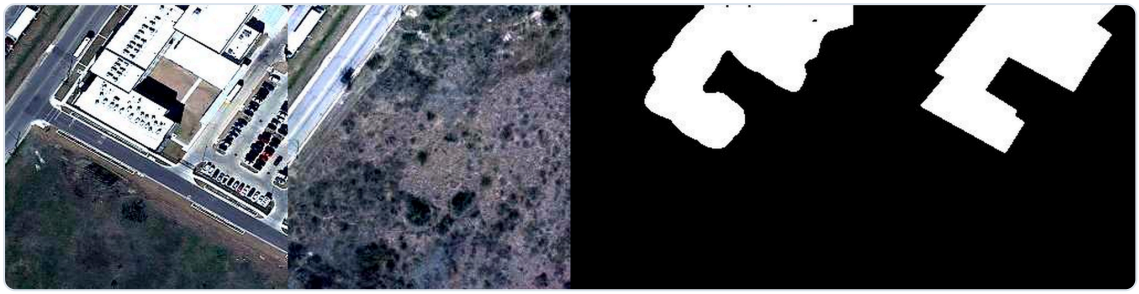


图 4　典型正确案例：后时相中原有建筑被拆除、变为裸地，模型将整片变化区域完整检出，边界与真值高度吻合（预测变化占比 0.1783，真值 0.1897）



图 5　典型误报案例：真值为无变化区域，模型在若干位置产生了零散的小块误报（预测 0.0263，真值 0）。误报面积小且分布零散，可通过提高置信度阈值与连通域后处理进一步抑制

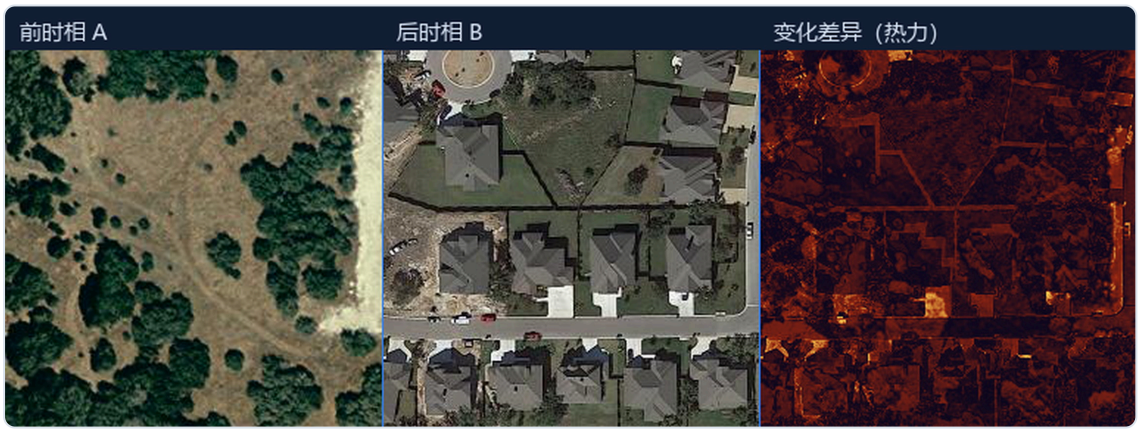


图 6　演示影像对的完整输出：前时相、后时相与变化差异热力图。新增建筑与道路在热力图上显著高亮，可直接用于人工复核

> **误差分析的价值：**把误差拆成 TP / FP / FN / TN 四类并着色呈现，可以直观回答「错在哪」。上例中的误报呈零散小块状，说明模型对高频纹理仍有一定敏感性，属于可通过阈值与后处理改善的误差类型，而不是结构性缺陷。

四、创新点与应用价值

（一）核心创新点

本作品的创新并非单点突破，而是「算法三项 + 端侧三项」的组合：算法侧针对变化检测的三个固有难点提出专门结构，端侧三项则打通从浮点权重到可交付系统的三个工程断点。

序号	创新点	价值
①	**RTRF 互易时相响应融合** 同时构造差异、能量与一致性三种响应，再做通道路由与空间路由	把光照阴影、季节差异等伪变化与真实地物变化区分开，从源头降低误报
②	**MSRB 多尺度细化桥** 尺度上下文聚合 + 跨尺度细节融合	兼顾从单栋建筑到大片区开发的尺度跨度，缓解小目标漏检
③	**SAM 注意力解码** 解码阶段对通道与空间位置重新加权	守住道路、田埂、围栏等细长边界，提升面积统计的可用性
④	**面向边缘芯片的结构前置适配** 以目标架构的算子集与数值格式反向约束网络结构与导出方式	避免「先在服务器上做精、再想办法塞进板子」的返工循环
⑤	**真实数据校准的量化策略** 60 组真实样本校准，配合浮点自检交叉验证	在压缩约 68% 体积的同时保住精度，形成可复现的量化路径
⑥	**端侧「可视化—可量化—可解释」闭环** 六视图联动、四色误差图、精度指标与视觉大模型语义解释集成于同一界面	把检测结果从单个二值掩膜，升级为一线人员可直接使用与判断的信息

> 三项算法创新 + 三项端侧创新，共同构成一套「为边缘硬件而设计」的变化检测方案：算法在结构上就为量化留出余量，工程流程又用真实数据把量化误差压回可接受范围，二者互为前提。

（二）应用场景与推广

本作品面向的是「需要到现场、且现场没有网」的一类遥感解译需求。端侧推理把原本依赖云端的能力前移到作业现场，在三个方向上直接对应真实业务：

应用场景	核心需求	端侧方案提供的价值
灾害评估	尽快掌握损毁范围与面积	现场直接给出变化区域与面积统计，不必等待影像回传与云端排队，为救援决策争取时间
城市更新与违建监管	定期比对新增建筑与地表变化	自动圈出变化图斑，把「人工逐幅排查」变为「按图斑核查」，显著减少工作量
国土动态监测	需要可核验的图斑与面积数据	四色误差图与逐像素指标提供可复核依据，便于形成规范的监测记录

三种部署形态

无人机
机载端侧推理
作业区无网亦可出结果

地面巡检
巡检设备就地检测
结果当场可查

调度平台
变化图斑与面积数据
回传至指挥与监管系统

可移植性与演进方向

整条链路与具体模型解耦：更换网络定义与权重，重新执行导出与量化即可平移到其他边缘平台，具备良好的可移植性。在此基础上，后续可沿两个方向延伸——一是把单幅检测扩展为**批量评估与长期序列比对**，形成区域变化的趋势记录；二是把变化图斑接入**风险预警看板**，由「发现变化」进一步走到「评估风险、提示处置」，使系统从检测工具演进为服务于国土监管与应急调度的端侧感知节点。

> 一句话总结：用自研轻量化算法把变化检测能力压缩进 3.2 MB，再把它交给一块 4 GB 的国产边缘板卡——让遥感解译第一次可以发生在数据产生的地方。

五、附录

（一）关键参数速查

环节	参数
训练	骨干 MobileNetV2（权重共享）；总参数量 2,477,892；输入 x1 / x2 各 `[1,3,256,256]`，输出 `change_map`；浮点权重 10.2 MB
导出	PyTorch → ONNX，opset 11；导出前校验输出形状为 `(1,1,256,256)`
量化	hb_mapper 1.24.3；`march = bayes-e`；int8；校准 60 组真实样本，每组 786,432 字节
板端	模型 `repbnet_cd.bin`（3,279,032 字节）；运行时 `hbm_runtime`；判定阈值 0.5
指标	LEVIR-CD 全量 2048 对：P 0.8782 / R 0.8517 / F1 0.8648 / IoU 0.7617；UAV：F1 0.7752 / IoU 0.6329
界面	板载 1024×600 IPS 触摸屏；本地 Web 服务，浏览器访问；模型常驻内存只加载一次

（二）端侧文件清单与复现步骤

文件	作用
repbnet_cd.bin	板端可执行的 int8 定点模型，全部推理的基础
infer.py	推理封装：预处理、模型加载、概率图与统计量计算
webapp.py	端侧工作站主程序，提供界面与各功能接口
explain.py	调用视觉大模型，生成变化的中文语义解释
batch_eval.py	批量评估脚本，逐对推理并计算整体精度指标
static / templates	前端样式、交互脚本与页面模板
demo	演示用影像对与真值（含 A / B / label 子目录）

复现步骤（板端）：

```
# 1. 启动端侧工作站（界面自动在全屏浏览器中打开）
cd ~/deploy && /usr/bin/python3 webapp.py
# 2. 批量评估：对测试集逐对推理并给出整体指标
/usr/bin/python3 batch_eval.py --data demo --bin repbnet_cd.bin --thresh 0.5
# 3. 单对影像的命令行推理与 AI 解释
/usr/bin/python3 explain.py demo/A/test_2_0.png demo/B/test_2_0.png
```

> **提交说明：**作品方案按大赛要求统一保存为 PDF 格式，文件大小不超过 10 M；文中图表均来自板端实测输出，可按上述步骤重新生成。